

最小二乘理论与矩阵分解专题讲义

从经典理论到现代应用的系统性阐述

专题讲义

2025 年 5 月 24 日

摘要

本讲义系统地介绍最小二乘理论及其相关的矩阵分解方法，从经典的向量最小二乘问题出发，逐步扩展到矩阵最小二乘、约束优化、以及在概率论中的应用。重点阐述矩阵分解（SVD、QR等）在解决这类问题中的核心作用，并展示这些工具如何应用于现代统计和信号处理问题中。

目录

1	引言	3
2	经典最小二乘理论	3
2.1	问题的提出	3
2.2	几何解释	3
2.3	正规方程	4
2.4	解的存在性和唯一性	4
3	矩阵分解理论	4
3.1	奇异值分解(SVD)	4
3.2	Moore-Penrose伪逆	5
3.3	QR分解	5
4	投影理论	5
4.1	正交投影	5
4.2	投影算子的矩阵表示	6
5	广义最小二乘问题	6
5.1	约束最小二乘	6
5.2	加权最小二乘	6
6	矩阵最小二乘问题	6
6.1	Frobenius范数最小化	6
6.2	多重约束的矩阵问题	7

7 矩阵分解在最小二乘中的核心作用	7
7.1 分解的统一观点	7
7.2 四个基本子空间	8
7.3 投影的矩阵表示	8
8 在概率论中的应用：条件分布构造	9
8.1 高斯分布的线性约束	9
8.2 构造的几何直观	9
8.3 矩阵情况的推广	9
9 数值方法与计算考虑	10
9.1 条件数与数值稳定性	10
9.2 正则化方法	10
10 总结与展望	10
10.1 理论体系的统一性	10
10.2 矩阵分解的核心地位	10
10.3 现代应用	11

1 引言

现代的最小二乘理论不仅包括经典的线性回归问题，还涵盖了矩阵优化、约束优化、正则化方法等多个方面。

矩阵分解技术，特别是奇异值分解(SVD)和QR分解，在解决最小二乘问题中发挥着核心作用。这些分解不仅提供了数值稳定的计算方法，更重要的是，它们揭示了问题的几何结构，使我们能够深入理解解的性质和存在性。

本讲义将系统地构建这一理论体系，从基础概念出发，逐步建立完整的理论框架。

2 经典最小二乘理论

2.1 问题的提出

最小二乘问题

给定矩阵 $A \in \mathbb{R}^{m \times n}$ 和向量 $\mathbf{b} \in \mathbb{R}^m$ ，最小二乘问题是寻找向量 $\mathbf{x} \in \mathbb{R}^n$ 使得

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax} - \mathbf{b}\|_2^2$$

其中 $\|\cdot\|_2$ 表示欧几里得范数。

这个问题的几何意义是：在 A 的列空间 $\text{Col}(A) = \{\mathbf{Ax} : \mathbf{x} \in \mathbb{R}^n\}$ 中寻找最接近向量 \mathbf{b} 的点。

2.2 几何解释

最小二乘问题本质上是一个投影问题。设 \mathbf{x}^* 是最小二乘解，则 \mathbf{Ax}^* 是 \mathbf{b} 在 $\text{Col}(A)$ 上的正交投影。

定理 2.1 (最小二乘解的几何特征). 向量 \mathbf{x}^* 是最小二乘问题的解当且仅当残差向量 $\mathbf{r} = \mathbf{b} - \mathbf{Ax}^*$ 正交于 A 的列空间，即

$$A^T(\mathbf{b} - \mathbf{Ax}^*) = \mathbf{0}$$

证明. 设 \mathbf{x}^* 为最小二乘解，对于任意 $\mathbf{h} \in \mathbb{R}^n$ ，定义函数

$$f(t) = \|\mathbf{A}(\mathbf{x}^* + t\mathbf{h}) - \mathbf{b}\|_2^2$$

由于 \mathbf{x}^* 是最优解， $f(t)$ 在 $t = 0$ 处取得最小值，因此 $f'(0) = 0$ 。

计算导数：

$$f(t) = \|\mathbf{Ax}^* + t\mathbf{Ah} - \mathbf{b}\|_2^2 \quad (1)$$

$$= (\mathbf{r} + t\mathbf{Ah})^T (\mathbf{r} + t\mathbf{Ah}) \quad (2)$$

$$= \|\mathbf{r}\|_2^2 + 2t\mathbf{r}^T \mathbf{Ah} + t^2 \|\mathbf{Ah}\|_2^2 \quad (3)$$

其中 $\mathbf{r} = \mathbf{Ax}^* - \mathbf{b}$ 。因此

$$f'(0) = 2\mathbf{r}^T \mathbf{Ah} = 0$$

由于这对任意 \mathbf{h} 成立，得到 $A^T \mathbf{r} = \mathbf{0}$ 。

□

2.3 正规方程

从几何特征可以直接得到著名的正规方程：

正规方程

最小二乘问题的解满足正规方程：

$$A^T A \mathbf{x} = A^T \mathbf{b}$$

当 $A^T A$ 可逆时，唯一解为：

$$\mathbf{x}^* = (A^T A)^{-1} A^T \mathbf{b}$$

2.4 解的存在性和唯一性

定理 2.2 (最小二乘解的存在性和唯一性). (i) 最小二乘问题总是有解。

(ii) 当 A 的列线性无关 (即 $\text{rank}(A) = n$) 时，解唯一。

(iii) 当 A 的列线性相关时，解不唯一，但最小范数解唯一。

3 矩阵分解理论

矩阵分解是解决最小二乘问题的核心工具。不同的分解方法揭示了矩阵的不同结构特征。

3.1 奇异值分解(SVD)

奇异值分解

对于任意矩阵 $A \in \mathbb{R}^{m \times n}$ ，存在正交矩阵 $U \in \mathbb{R}^{m \times m}$ 和 $V \in \mathbb{R}^{n \times n}$ ，使得

$$A = U \Sigma V^T$$

其中 $\Sigma \in \mathbb{R}^{m \times n}$ 是对角矩阵，对角元素 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ ($r = \text{rank}(A)$) 称为奇异值。

SVD的几何意义深刻：它将任意线性变换分解为三个基本变换的复合：旋转、缩放、再旋转。

SVD的几何意义

SVD分解 $A = U \Sigma V^T$ 可以理解为：

- V^T ：在输入空间进行旋转，将输入向量对齐到主要方向
- Σ ：沿主要方向进行缩放，缩放因子为奇异值
- U ：在输出空间进行旋转，将结果对齐到输出空间的主要方向

3.2 Moore-Penrose伪逆

当 $A^T A$ 不可逆时，我们需要更一般的工具来求解最小二乘问题。

定义 3.1 (Moore-Penrose伪逆). 矩阵 $A \in \mathbb{R}^{m \times n}$ 的Moore-Penrose伪逆 $A^+ \in \mathbb{R}^{n \times m}$ 定义为满足以下四个Penrose条件的唯一矩阵：

1. $AA^+A = A$
2. $A^+AA^+ = A^+$
3. $(AA^+)^T = AA^+$
4. $(A^+A)^T = A^+A$

使用SVD可以显式构造伪逆：

定理 3.1 (伪逆的SVD表示). 设 $A = U\Sigma V^T$ 是 A 的SVD分解，则

$$A^+ = V\Sigma^+U^T$$

其中 $\Sigma^+ \in \mathbb{R}^{n \times m}$ 定义为：当 $\Sigma_{ii} \neq 0$ 时， $\Sigma_{ii}^+ = 1/\Sigma_{ii}$ ；否则 $\Sigma_{ii}^+ = 0$ 。

3.3 QR分解

QR分解在数值计算中具有更好的稳定性。

定义 3.2 (QR分解). 对于列满秩矩阵 $A \in \mathbb{R}^{m \times n}$ ($m \geq n$)，存在正交矩阵 $Q \in \mathbb{R}^{m \times m}$ 和上三角矩阵 $R \in \mathbb{R}^{n \times n}$ ，使得

$$A = Q \begin{bmatrix} R \\ 0 \end{bmatrix}$$

通常写作 $A = Q_1 R$ ，其中 $Q_1 \in \mathbb{R}^{m \times n}$ 是 Q 的前 n 列。

4 投影理论

投影理论是理解最小二乘问题几何结构的关键。

4.1 正交投影

正交投影算子

设 $S \subseteq \mathbb{R}^m$ 是子空间，正交投影算子 $P_S : \mathbb{R}^m \rightarrow S$ 定义为：对任意 $\mathbf{v} \in \mathbb{R}^m$ ， $P_S \mathbf{v}$ 是 S 中最接近 \mathbf{v} 的向量。

定理 4.1 (投影算子的性质). 正交投影算子 P_S 具有以下性质：

- (i) $P_S^2 = P_S$ (幂等性)
- (ii) $P_S^T = P_S$ (自伴随性)

$$(iii) \text{ Range}(P_S) = S$$

$$(iv) \text{ Null}(P_S) = S^\perp$$

$$(v) \text{ 对任意 } \mathbf{v} \in \mathbb{R}^m, \text{ 有 } \mathbf{v} - P_S \mathbf{v} \perp S$$

4.2 投影算子的矩阵表示

定理 4.2 (列空间投影算子). 设 $A \in \mathbb{R}^{m \times n}$, 则 \mathbf{b} 在 $\text{Col}(A)$ 上的投影算子为:

$$P_{\text{Col}(A)} = A(A^T A)^{-1} A^T \quad (\text{当 } A \text{ 列满秩时})$$

一般情况下:

$$P_{\text{Col}(A)} = AA^+$$

定理 4.3 (零空间投影算子). 零空间 $\text{Null}(A)$ 的投影算子为:

$$P_{\text{Null}(A)} = I - A^+ A$$

5 广义最小二乘问题

5.1 约束最小二乘

考虑带等式约束的最小二乘问题:

$$\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2^2 \quad \text{subject to} \quad \mathbf{Cx} = \mathbf{d}$$

定理 5.1 (约束最小二乘解). 约束最小二乘问题的解为:

$$\mathbf{x}^* = A^+ \mathbf{b} + (I - A^+ A) C^+ (\mathbf{d} - C A^+ \mathbf{b})$$

其中第一项是无约束最小二乘解, 第二项是约束修正项。

5.2 加权最小二乘

当观测具有不同精度时, 使用加权最小二乘:

$$\min_{\mathbf{x}} \|W^{1/2}(\mathbf{Ax} - \mathbf{b})\|_2^2 = \min_{\mathbf{x}} (\mathbf{Ax} - \mathbf{b})^T W (\mathbf{Ax} - \mathbf{b})$$

其中 W 是正定权重矩阵。

定理 5.2 (加权最小二乘解). 加权最小二乘问题的解为:

$$\mathbf{x}^* = (A^T W A)^{-1} A^T W \mathbf{b}$$

6 矩阵最小二乘问题

现在我们将理论扩展到矩阵情况, 这在现代应用中越来越重要。

6.1 Frobenius 范数最小化

矩阵最小二乘问题

给定矩阵 $A \in \mathbb{R}^{m \times p}$, $B \in \mathbb{R}^{q \times n}$, $C \in \mathbb{R}^{m \times n}$, 矩阵最小二乘问题是寻找矩阵 $X \in \mathbb{R}^{p \times q}$ 使得

$$\min_X \|AXB - C\|_F^2$$

其中 $\|\cdot\|_F$ 是Frobenius范数。

定理 6.1 (矩阵最小二乘解). 矩阵最小二乘问题 $\min_X \|AXB - C\|_F^2$ 的解为:

$$X^* = A^+CB^+$$

当 A 和 B 分别列满秩和行满秩时, 解为:

$$X^* = (A^T A)^{-1} A^T C B^T (B B^T)^{-1}$$

证明. 使用向量化技巧. 注意到 $\text{vec}(AXB) = (B^T \otimes A)\text{vec}(X)$, 其中 \otimes 是Kronecker积。

因此原问题等价于:

$$\min_{\text{vec}(X)} \|(B^T \otimes A)\text{vec}(X) - \text{vec}(C)\|_2^2$$

这是标准的向量最小二乘问题, 解为:

$$\text{vec}(X^*) = (B^T \otimes A)^+ \text{vec}(C)$$

利用Kronecker积伪逆的性质 $(B^T \otimes A)^+ = (B^T)^+ \otimes A^+ = B \otimes A^+$ (当 A 和 B^T 列满秩时), 得到

$$\text{vec}(X^*) = (B \otimes A^+) \text{vec}(C) = \text{vec}(A^+CB^+)$$

因此 $X^* = A^+CB^+$. □

6.2 多重约束的矩阵问题

考虑同时满足左乘和右乘约束的问题:

$$\min_X \|X\|_F^2 \quad \text{subject to} \quad AX = C, \quad XB = D$$

这种问题在统计学中的条件分布分析中经常出现。

定理 6.2 (双约束矩阵最小二乘). 问题 $\min_X \|X\|_F^2$ 在约束 $AX = C$ 和 $XB = D$ 下的解 (当约束相容时) 为:

$$X^* = A^+C + DB^+ - A^+ADB^+$$

其中约束相容条件为 $A^+CB = D$ 。

7 矩阵分解在最小二乘中的核心作用

7.1 分解的统一观点

所有主要的矩阵分解都可以理解为对特定几何结构的揭示:

矩阵分解的本质作用

- **SVD**: 揭示矩阵的完整几何结构, 包括四个基本子空间的正交基
- **QR分解**: 将列空间的基正交化, 保持数值稳定性
- **特征值分解**: 对称矩阵的主轴方向分析
- **Cholesky分解**: 正定矩阵的平方根分解

在最小二乘问题中, 这些分解的作用是:

1. **降维**: 将高维问题分解为低维子问题
2. **去耦**: 将耦合的变量分离为独立的部分
3. **投影**: 构造到各个子空间的投影算子
4. **稳定**: 提供数值稳定的计算方法

7.2 四个基本子空间

对于矩阵 $A \in \mathbb{R}^{m \times n}$, SVD分解揭示了四个基本子空间:

定理 7.1 (四个基本子空间). 设 $A = U\Sigma V^T$ 是SVD分解, $r = \text{rank}(A)$, 则:

$$\text{Col}(A) = \{u_1, u_2, \dots, u_r\} \quad (4)$$

$$\text{Null}(A^T) = \{u_{r+1}, u_{r+2}, \dots, u_m\} \quad (5)$$

$$\text{Row}(A) = \{v_1, v_2, \dots, v_r\} \quad (6)$$

$$\text{Null}(A) = \{v_{r+1}, v_{r+2}, \dots, v_n\} \quad (7)$$

其中 u_i 和 v_i 分别是 U 和 V 的列向量。

这四个子空间满足正交关系: $\text{Col}(A) \perp \text{Null}(A^T)$, $\text{Row}(A) \perp \text{Null}(A)$ 。

7.3 投影的矩阵表示

定理 7.2 (SVD投影表示). 使用SVD分解, 各子空间的投影算子为:

$$P_{\text{Col}(A)} = \sum_{i=1}^r u_i u_i^T = U_r U_r^T \quad (8)$$

$$P_{\text{Null}(A^T)} = \sum_{i=r+1}^m u_i u_i^T = U_{m-r} U_{m-r}^T \quad (9)$$

$$P_{\text{Row}(A)} = \sum_{i=1}^r v_i v_i^T = V_r V_r^T \quad (10)$$

$$P_{\text{Null}(A)} = \sum_{i=r+1}^n v_i v_i^T = V_{n-r} V_{n-r}^T \quad (11)$$

其中 U_r, V_r 分别是 U, V 的前 r 列, U_{m-r}, V_{n-r} 是剩余列。

8 在概率论中的应用：条件分布构造

8.1 高斯分布的线性约束

考虑高斯随机向量 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 I)$ 在线性约束 $D\mathbf{z} = \mathbf{b}$ 下的条件分布。

这个问题的解决思路体现了最小二乘理论的完美应用：

条件分布的构造原理

线性约束下高斯分布的条件分布可以分解为：

$$\mathbf{z}|D\mathbf{z} = \mathbf{b} = (\text{确定性最小范数解}) + (\text{投影到零空间的噪声})$$

具体地：

$$\mathbf{z}|D\mathbf{z} = \mathbf{b} \stackrel{d}{=} D^+ \mathbf{b} + P_{\text{Null}(D)} \tilde{\mathbf{z}}$$

其中 $\tilde{\mathbf{z}}$ 是 \mathbf{z} 的独立拷贝。

8.2 构造的几何直观

这个构造的几何意义是：

1. $D^+ \mathbf{b}$ 是满足约束 $D\mathbf{z} = \mathbf{b}$ 的最小范数解
2. $P_{\text{Null}(D)} \tilde{\mathbf{z}}$ 是投影到 D 零空间的独立高斯噪声
3. 两部分正交，因此可以独立处理

8.3 矩阵情况的推广

对于矩阵约束问题：给定 $A \sim \mathcal{N}(0, I)$ （元素独立），约束 $AQ = Y$ 和 $M^T A = X^T$ ，条件分布为：

$$A|_{\text{约束}} \stackrel{d}{=} E + \mathcal{P}(\tilde{A})$$

其中：

- E 是满足约束的最小Frobenius范数解
- \mathcal{P} 是投影到约束零空间的投影算子
- \tilde{A} 是 A 的独立拷贝

最小范数解的构造使用了我们前面发展的理论：

$$E = \operatorname{argmin}\{\|A\|_F^2 : AQ = Y, A^T M = X\}$$

投影算子的构造为：

$$\mathcal{P}(A) = P_{M^\perp} A P_{Q^\perp}$$

其中 $P_{M^\perp} = I - M(M^T M)^{-1} M^T$ ， $P_{Q^\perp} = I - Q(Q^T Q)^{-1} Q^T$ 。

9 数值方法与计算考虑

9.1 条件数与数值稳定性

定义 9.1 (条件数). 矩阵 A 的条件数定义为:

$$\kappa(A) = \|A\| \|A^+\| = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}$$

其中 $\sigma_{\max}, \sigma_{\min}$ 分别是最大和最小非零奇异值。

当 $\kappa(A)$ 很大时, 最小二乘问题是病态的, 数值解可能不可靠。

9.2 正则化方法

当问题病态时, 常用正则化方法:

定理 9.1 (Ridge回归). Ridge回归问题

$$\min_{\mathbf{x}} \|A\mathbf{x} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_2^2$$

的解为:

$$\mathbf{x}_\lambda = (A^T A + \lambda I)^{-1} A^T \mathbf{b}$$

正则化的几何意义是在原解附近寻找范数较小的解, 这在统计学中对应于引入先验信息。

10 总结与展望

10.1 理论体系的统一性

本讲义展示了最小二乘理论的统一性:

- 几何统一: 所有问题都可以理解为投影问题
- 代数统一: 矩阵分解提供了统一的解析工具
- 数值统一: 相同的数值方法适用于不同的问题变种

10.2 矩阵分解的核心地位

矩阵分解在最小二乘理论中的核心作用体现在:

1. 结构揭示: 分解揭示了问题的内在几何结构
2. 解的构造: 分解直接给出了解的显式表达式
3. 性质分析: 分解使我们能够分析解的存在性、唯一性等性质
4. 数值计算: 分解提供了数值稳定的计算方法

10.3 现代应用

这些理论在现代统计学、机器学习、信号处理中有广泛应用：

- 高维统计：稀疏回归、变量选择
- 机器学习：主成分分析、矩阵补全
- 信号处理：压缩感知、图像重构
- 概率论：条件分布、贝叶斯推断

理解这些基础理论对于掌握现代数据科学方法至关重要。

参考文献

- [1] G. H. Golub and C. F. Van Loan, *Matrix Computations*, 3rd ed. Johns Hopkins University Press, 1996.
- [2] L. N. Trefethen and D. Bau III, *Numerical Linear Algebra*. SIAM, 1997.
- [3] R. A. Horn and C. R. Johnson, *Matrix Analysis*, 2nd ed. Cambridge University Press, 2012.
- [4] A. Björck, *Numerical Methods for Least Squares Problems*. SIAM, 1996.
- [5] G. W. Stewart, *Matrix Algorithms Volume I: Basic Decompositions*. SIAM, 1998.
- [6] D. S. Watkins, *Fundamentals of Matrix Computations*, 3rd ed. Wiley, 2010.