

# 最小均方误差估计理论

## Minimum Mean Square Error (MMSE) Estimation

统计信号处理笔记

2025 年 5 月 24 日

### 目录

1	引言与动机	1
2	基本概念与定义	2
3	核心理论结果	2
3.1	MMSE估计器的最优性	2
3.2	正交性原理	3
4	高斯情形下的MMSE	3
4.1	联合高斯分布的MMSE	4
4.2	线性MMSE (LMMSE)估计	4
5	实际应用示例	5
6	重要性质与扩展	6
6.1	MMSE的不变性质	6
6.2	贝叶斯观点	6
7	计算复杂度与实现	6
8	总结	7

### 1 引言与动机

在统计学和信号处理中，我们经常面临从噪声观测中估计未知参数或信号的问题。最小均方误差（MMSE）估计是一种基础且重要的估计准则，它在理论上具有最优性，在实践中具有广泛的应用价值。

**注记 1.1: MMSE的重要性**

MMSE估计不仅提供了理论上的最优解，还为许多实际算法（如Wiener滤波、Kalman滤波等）提供了理论基础。

**2 基本概念与定义****定义 2.1: MMSE估计器**

设  $\mathbf{X} \in \mathbb{R}^n$  是未知随机向量， $\mathbf{Y} \in \mathbb{R}^m$  是观测向量。MMSE估计器  $\hat{\mathbf{X}}_{\text{MMSE}}$  定义为最小化均方误差的估计器：

$$\hat{\mathbf{X}}_{\text{MMSE}} = \underset{\hat{\mathbf{X}}(\mathbf{Y})}{\operatorname{argmin}} \mathbb{E} [\|\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Y})\|^2] \quad (1)$$

其中期望运算是关于联合分布  $p(\mathbf{X}, \mathbf{Y})$  进行的， $\|\cdot\|$  表示欧几里得范数。

**定义 2.2: 均方误差**

对于任意估计器  $\hat{\mathbf{X}}(\mathbf{Y})$ ，其均方误差定义为：

$$\text{MSE}(\hat{\mathbf{X}}) = \mathbb{E} [\|\mathbf{X} - \hat{\mathbf{X}}(\mathbf{Y})\|^2] = \mathbb{E} \left[ \sum_{i=1}^n (X_i - \hat{X}_i(\mathbf{Y}))^2 \right] \quad (2)$$

**3 核心理论结果****3.1 MMSE估计器的最优性****定理 3.1: MMSE估计器的解析形式**

MMSE估计器由条件期望给出：

$$\hat{\mathbf{X}}_{\text{MMSE}}(\mathbf{Y}) = \mathbb{E}[\mathbf{X} | \mathbf{Y}] \quad (3)$$

此时的最小均方误差为：

$$\text{MMSE} = \mathbb{E} [\|\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}]\|^2] \quad (4)$$

证明. 对于任意估计器  $\hat{\mathbf{X}}(\mathbf{Y})$ ，将估计误差分解为：

$$\mathbf{X} - \hat{\mathbf{X}} = \underbrace{(\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}])}_{\mathbf{e}_{\text{irr}}} + \underbrace{(\mathbb{E}[\mathbf{X} | \mathbf{Y}] - \hat{\mathbf{X}})}_{\mathbf{e}_{\text{red}}} \quad (5)$$

其中  $\mathbf{e}_{\text{irr}}$  为不可约误差， $\mathbf{e}_{\text{red}}$  为可约误差。

计算均方误差：

$$\mathbb{E}[\|\mathbf{X} - \hat{\mathbf{X}}\|^2] = \mathbb{E}[\|\mathbf{e}_{\text{irr}} + \mathbf{e}_{\text{red}}\|^2] \quad (6)$$

$$= \mathbb{E}[\|\mathbf{e}_{\text{irr}}\|^2] + \mathbb{E}[\|\mathbf{e}_{\text{red}}\|^2] + 2\mathbb{E}[\mathbf{e}_{\text{irr}}^T \mathbf{e}_{\text{red}}] \quad (7)$$

关键是证明交叉项为零。利用条件期望的性质：

$$\mathbb{E}[\mathbf{e}_{\text{irr}}^T \mathbf{e}_{\text{red}}] = \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}])^T (\mathbb{E}[\mathbf{X} | \mathbf{Y}] - \hat{\mathbf{X}})] \quad (8)$$

$$= \mathbb{E}[\mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}])^T (\mathbb{E}[\mathbf{X} | \mathbf{Y}] - \hat{\mathbf{X}}) | \mathbf{Y}]] \quad (9)$$

$$= \mathbb{E}[(\mathbb{E}[\mathbf{X} | \mathbf{Y}] - \hat{\mathbf{X}})^T \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}]) | \mathbf{Y}]] \quad (10)$$

$$= \mathbb{E}[(\mathbb{E}[\mathbf{X} | \mathbf{Y}] - \hat{\mathbf{X}})^T \cdot \mathbf{0}] = 0 \quad (11)$$

因此：

$$\mathbb{E}[\|\mathbf{X} - \hat{\mathbf{X}}\|^2] = \underbrace{\mathbb{E}[\|\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}]\|^2]}_{\text{不可约误差}} + \underbrace{\mathbb{E}[\|\mathbb{E}[\mathbf{X} | \mathbf{Y}] - \hat{\mathbf{X}}\|^2]}_{\geq 0} \quad (12)$$

显然，当 $\hat{\mathbf{X}} = \mathbb{E}[\mathbf{X} | \mathbf{Y}]$ 时，第二项为零，此时MSE达到最小值。  $\square$

### 3.2 正交性原理

#### 定理 3.2: 正交性原理

MMSE估计误差 $\mathbf{e} = \mathbf{X} - \hat{\mathbf{X}}_{\text{MMSE}}$ 与观测 $\mathbf{Y}$ 的任意函数正交：

$$\mathbb{E}[\mathbf{e} g(\mathbf{Y})^T] = \mathbf{0} \quad \forall \text{可测函数 } g(\cdot) \quad (13)$$

特别地， $\mathbb{E}[\mathbf{e} | \mathbf{Y}] = \mathbf{0}$ 。

证明. 由于 $\mathbf{e} = \mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}]$ ，利用条件期望的性质：

$$\mathbb{E}[\mathbf{e} g(\mathbf{Y})^T] = \mathbb{E}[\mathbb{E}[\mathbf{e} g(\mathbf{Y})^T | \mathbf{Y}]] \quad (14)$$

$$= \mathbb{E}[g(\mathbf{Y})^T \mathbb{E}[\mathbf{e} | \mathbf{Y}]] \quad (15)$$

$$= \mathbb{E}[g(\mathbf{Y})^T \mathbb{E}[(\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}]) | \mathbf{Y}]] \quad (16)$$

$$= \mathbb{E}[g(\mathbf{Y})^T (\mathbb{E}[\mathbf{X} | \mathbf{Y}] - \mathbb{E}[\mathbf{X} | \mathbf{Y}])] \quad (17)$$

$$= \mathbb{E}[g(\mathbf{Y})^T \cdot \mathbf{0}] = \mathbf{0} \quad (18)$$

$\square$

#### 注记 3.1: 正交性的几何解释

正交性原理表明，MMSE估计误差在由观测 $\mathbf{Y}$ 的所有函数张成的空间中的投影为零，这是最优估计的几何特征。

## 4 高斯情形下的MMSE

#### 4.1 联合高斯分布的MMSE

##### 定理 4.1: 高斯向量的MMSE估计

若 $\mathbf{X}$ 和 $\mathbf{Y}$ 服从联合高斯分布:

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \sim \mathcal{N} \left( \begin{bmatrix} \boldsymbol{\mu}_X \\ \boldsymbol{\mu}_Y \end{bmatrix}, \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix} \right) \quad (19)$$

则MMSE估计器为线性函数:

$$\hat{\mathbf{X}}_{\text{MMSE}} = \boldsymbol{\mu}_X + \Sigma_{XY} \Sigma_{YY}^{-1} (\mathbf{Y} - \boldsymbol{\mu}_Y) \quad (20)$$

对应的最小均方误差为:

$$\text{MMSE} = \text{tr}(\Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}) \quad (21)$$

证明. 对于联合高斯分布, 条件分布 $\mathbf{X} | \mathbf{Y}$ 也是高斯分布:

$$\mathbf{X} | \mathbf{Y} \sim \mathcal{N}(\boldsymbol{\mu}_{X|Y}, \Sigma_{X|Y}) \quad (22)$$

其中:

$$\boldsymbol{\mu}_{X|Y} = \boldsymbol{\mu}_X + \Sigma_{XY} \Sigma_{YY}^{-1} (\mathbf{Y} - \boldsymbol{\mu}_Y) \quad (23)$$

$$\Sigma_{X|Y} = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX} \quad (24)$$

由于 $\mathbb{E}[\mathbf{X} | \mathbf{Y}] = \boldsymbol{\mu}_{X|Y}$ , 所以MMSE估计器即为上述线性形式。

最小均方误差为:

$$\text{MMSE} = \mathbb{E}[\|\mathbf{X} - \mathbb{E}[\mathbf{X} | \mathbf{Y}]\|^2] = \text{tr}(\text{Var}(\mathbf{X} | \mathbf{Y})) = \text{tr}(\Sigma_{X|Y}) \quad (25)$$

□

#### 4.2 线性MMSE (LMMSE)估计

##### 定义 4.1: 线性MMSE估计器

当估计器限制为线性形式 $\hat{\mathbf{X}} = \mathbf{A}\mathbf{Y} + \mathbf{b}$ 时, 线性MMSE (LMMSE) 估计器定义为:

$$\hat{\mathbf{X}}_{\text{LMMSE}} = \underset{\mathbf{A}, \mathbf{b}}{\text{argmin}} \mathbb{E} [\|\mathbf{X} - \mathbf{A}\mathbf{Y} - \mathbf{b}\|^2] \quad (26)$$

##### 定理 4.2: LMMSE估计器的解析解

LMMSE估计器为:

$$\hat{\mathbf{X}}_{\text{LMMSE}} = \boldsymbol{\mu}_X + \Sigma_{XY} \Sigma_{YY}^{-1} (\mathbf{Y} - \boldsymbol{\mu}_Y) \quad (27)$$

$$\mathbf{A}_{\text{opt}} = \Sigma_{XY} \Sigma_{YY}^{-1} \quad (28)$$

$$\mathbf{b}_{\text{opt}} = \boldsymbol{\mu}_X - \mathbf{A}_{\text{opt}} \boldsymbol{\mu}_Y \quad (29)$$

证明. 将MSE展开:

$$\mathbb{E}[\|\mathbf{X} - A\mathbf{Y} - \mathbf{b}\|^2] \quad (30)$$

$$= \mathbb{E}[\|\mathbf{X} - \boldsymbol{\mu}_X - A(\mathbf{Y} - \boldsymbol{\mu}_Y) - (\mathbf{b} + A\boldsymbol{\mu}_Y - \boldsymbol{\mu}_X)\|^2] \quad (31)$$

令  $\tilde{\mathbf{X}} = \mathbf{X} - \boldsymbol{\mu}_X$ ,  $\tilde{\mathbf{Y}} = \mathbf{Y} - \boldsymbol{\mu}_Y$ ,  $\mathbf{c} = \mathbf{b} + A\boldsymbol{\mu}_Y - \boldsymbol{\mu}_X$ , 则:

$$\text{MSE} = \mathbb{E}[\|\tilde{\mathbf{X}} - A\tilde{\mathbf{Y}} - \mathbf{c}\|^2] \quad (32)$$

对 $\mathbf{c}$ 求偏导并令其为零:

$$\frac{\partial}{\partial \mathbf{c}} \text{MSE} = -2\mathbb{E}[\tilde{\mathbf{X}} - A\tilde{\mathbf{Y}}] = 0 \quad (33)$$

由于 $\mathbb{E}[\tilde{\mathbf{X}}] = \mathbb{E}[\tilde{\mathbf{Y}}] = \mathbf{0}$ , 得 $\mathbf{c}_{\text{opt}} = \mathbf{0}$ 。

对 $A$ 求偏导并令其为零:

$$\frac{\partial}{\partial A} \text{MSE} = -2\mathbb{E}[\tilde{\mathbf{X}}\tilde{\mathbf{Y}}^T] + 2A\mathbb{E}[\tilde{\mathbf{Y}}\tilde{\mathbf{Y}}^T] = 0 \quad (34)$$

因此:

$$A_{\text{opt}} = \mathbb{E}[\tilde{\mathbf{X}}\tilde{\mathbf{Y}}^T](\mathbb{E}[\tilde{\mathbf{Y}}\tilde{\mathbf{Y}}^T])^{-1} = \Sigma_{XY}\Sigma_{YY}^{-1} \quad (35)$$

□

#### 定理 4.3: 高斯情形下MMSE与LMMSE的等价性

当 $\mathbf{X}$ 和 $\mathbf{Y}$ 联合高斯分布时:

$$\hat{\mathbf{X}}_{\text{MMSE}} = \hat{\mathbf{X}}_{\text{LMMSE}} \quad (36)$$

## 5 实际应用示例

### 例题 5.1: 一维标量估计

考虑标量情形:  $X \sim \mathcal{N}(0, \sigma_X^2)$ , 观测模型为 $Y = X + N$ , 其中 $N \sim \mathcal{N}(0, \sigma_N^2)$ 且 $X \perp N$ 。求MMSE估计器及其性能。

解: 首先计算必要的统计量:

$$\mu_X = 0, \quad \mu_Y = 0 \quad (37)$$

$$\Sigma_{XX} = \sigma_X^2 \quad (38)$$

$$\Sigma_{YY} = \sigma_X^2 + \sigma_N^2 \quad (39)$$

$$\Sigma_{XY} = \text{Cov}(X, Y) = \text{Cov}(X, X + N) = \sigma_X^2 \quad (40)$$

MMSE估计器为:

$$\hat{X}_{\text{MMSE}} = \frac{\sigma_X^2}{\sigma_X^2 + \sigma_N^2} Y = \frac{\text{SNR}}{1 + \text{SNR}} Y \quad (41)$$

其中 $\text{SNR} = \sigma_X^2 / \sigma_N^2$ 为信噪比。

最小均方误差为:

$$\text{MMSE} = \sigma_X^2 - \frac{(\sigma_X^2)^2}{\sigma_X^2 + \sigma_N^2} = \frac{\sigma_X^2 \sigma_N^2}{\sigma_X^2 + \sigma_N^2} \quad (42)$$

**例题 5.2: 向量Wiener滤波**

考虑向量观测模型:

$$\mathbf{Y} = \mathbf{H}\mathbf{X} + \mathbf{N} \quad (43)$$

其中  $\mathbf{H} \in \mathbb{R}^{m \times n}$  为已知矩阵,  $\mathbf{X} \sim \mathcal{N}(\mathbf{0}, \Sigma_X)$ ,  $\mathbf{N} \sim \mathcal{N}(\mathbf{0}, \Sigma_N)$ , 且  $\mathbf{X} \perp \mathbf{N}$ 。

解: 计算协方差矩阵:

$$\Sigma_{XY} = \text{Cov}(\mathbf{X}, \mathbf{Y}) = \text{Cov}(\mathbf{X}, \mathbf{H}\mathbf{X} + \mathbf{N}) = \Sigma_X \mathbf{H}^T \quad (44)$$

$$\Sigma_{YY} = \text{Var}(\mathbf{Y}) = \mathbf{H}\Sigma_X \mathbf{H}^T + \Sigma_N \quad (45)$$

MMSE估计器为:

$$\hat{\mathbf{X}}_{\text{MMSE}} = \Sigma_X \mathbf{H}^T (\mathbf{H}\Sigma_X \mathbf{H}^T + \Sigma_N)^{-1} \mathbf{Y} \quad (46)$$

这正是著名的Wiener滤波器公式。

## 6 重要性质与扩展

### 6.1 MMSE的不变性质

**定理 6.1: 仿射变换不变性**

若  $\mathbf{Z} = \mathbf{A}\mathbf{X} + \mathbf{b}$ , 则:

$$\hat{\mathbf{Z}}_{\text{MMSE}} = \mathbf{A}\hat{\mathbf{X}}_{\text{MMSE}} + \mathbf{b} \quad (47)$$

### 6.2 贝叶斯观点

从贝叶斯角度看, MMSE估计器等价于在平方损失函数下的贝叶斯估计器:

$$\hat{\mathbf{X}}_{\text{Bayes}} = \underset{\hat{\mathbf{X}}}{\text{argmin}} \mathbb{E}_{p(\mathbf{X}|\mathbf{Y})}[L(\mathbf{X}, \hat{\mathbf{X}})] \quad (48)$$

其中  $L(\mathbf{X}, \hat{\mathbf{X}}) = \|\mathbf{X} - \hat{\mathbf{X}}\|^2$ 。

## 7 计算复杂度与实现

在实际应用中, MMSE估计器的计算复杂度主要来自:

1. 协方差矩阵的计算和存储:  $O(n^2)$  空间复杂度
2. 矩阵求逆运算:  $O(m^3)$  时间复杂度 (其中  $m$  为观测维度)
3. 矩阵乘法运算:  $O(nm^2)$  时间复杂度

对于大规模问题, 可采用以下优化策略:

- 利用矩阵的特殊结构 (如对角、带状等)
- 使用迭代算法 (如共轭梯度法)
- 采用低秩近似技术
- 利用递推算法 (如Kalman滤波)

## 8 总结

MMSE估计理论为统计估计提供了坚实的理论基础。其主要优点包括：

- 理论最优性：在均方误差意义下达到最小值
- 解析解：在高斯情形下具有闭式解
- 几何直观：基于正交性原理的清晰几何解释
- 广泛应用：为许多实际算法提供理论支撑

然而，MMSE估计也有其局限性：

- 需要完整的统计信息（联合分布或二阶矩）
- 计算复杂度较高，特别是高维情形
- 对模型假设敏感，鲁棒性有限

在实际应用中，需要根据具体问题的特点，在估计性能、计算复杂度和鲁棒性之间进行权衡。